




Chat 首页 · 真实产品原型

Insurance AI Platform

保险问答、条款检索与保费估算
在同一个对话入口完成。

关于这个项目

这是一个保险 AI 产品原型，支持保险知识问答、条款查询、保费估算与 PDF 知识库管理。用户通过对话提出问题，系统调用相应的模型、检索或工具。

What I Designed

统一对话入口、回答来源，以及异常情况下的反馈规则。
重点是让用户知道如何使用回答，也知道何时结果尚不确定。

My Role

AI / Technical Product + Backend Implementation
需求拆解、用户流程、状态与系统边界设计；
在 AI / Codex 辅助下参与端到端实现与验证。

产品能力概览

Feature Map

用户与会话

注册 / 登录
创建与切换会话
历史消息 · 多轮会话

AI 保险服务

保险知识问答
条款知识查询
保费估算

知识库

PDF 上传 · 文档列表
索引状态 · 知识检索
回答来源

Agent 能力

LangGraph · DeepSeek
保费工具 · 检索工具
Tool Calling · 会话上下文

产品与系统保障

身份认证 · 资源归属 · 幂等 · 限流 · 请求状态 · 异常处理 · TraceId

为什么做这个原型

一个入口处理多种任务

用户无需区分背后的模型、
RAG 检索与计算工具。

回答要有可核对的依据

来源来自本轮真实检索，
帮助用户核对条款原文。

无法确认时，如实说明

将 UNKNOWN 与失败区分，
不生成未经确认的回答。

从一个问题，到可核对的回答

Conversation, tools & sources

用户无需理解 Agent、RAG 或 Tool，通过同一对话入口完成不同保险任务。
系统只在本轮真实发生知识检索时展示来源，不复用或伪造 Sources。

从提问到回答

登录 / 注册 → 创建 / 选择会话 → 提出保险问题

一般保险咨询

Agent / LLM 回答

条款知识查询

RAG 检索相关知识

保费估算

受控 Tool 执行计算

返回回答，继续对话

本轮发生真实检索？

是 → 展示 Sources

否 → 不展示、不复用来源

结果无法确认时，进入 UNKNOWN；不生成占位回答，不自动重试。

产品实际如何呈现

以下为原型的真实界面节选。

条款知识查询

从具体问题出发，
返回条款相关结论。

投保年龄规定

来源：《国寿重大疾病保险（政保合作版）（A款）利益条款》第二条 投保范围

一般投保条件

- 被保险人须为出生满28日以上、75周岁以下，身体健康者。

Policy / Terms · 回答中的投保年龄与一般条件

保费估算

通过受控工具计算，
展示估算的费率明细。

费率明细

- 基础费率：35元/万元/年
- 性别系数：0.92
- 年龄系数：1.3
- 期限系数：0.78

Premium Estimation · 费率明细节选

回答来源

文件名 · 页码 · 原文

回答来源

中国人寿.pdf 第 1 页 相关度 69%

国寿重大疾病保险（政保合作版）（A款）利益条款（第一页）中国人寿保险股份有限公司 国寿重大疾病保险（政保合作版）（A款）利益条款 第一条 保险合同构成 国寿重大疾病保险（政保合作版）（A款）合同（以下简称本合同）由保险单及所附国寿重大疾病保险（政保合作版）（A款）利益条款（以下简称本合同利益条款）、短期保险基本条款（以下简称本合同基本条款）、批注、附加批单、投保单，以及与本合同有关的投保文件、声明和其他书面协议共同构成。 第二条 投保范围 凡出生二十八日以上、七十五周岁以下，身体健康者均可作为被保险人，由具有完全民事行为能力的人或对其具有保险利益的其他人作为投保人，向本公司投保本保险。 若投保人在被保险七十六周岁至八十周岁期间投保本保险的，需要同时满足以下两个条件：1. 非首次投保；2. 投保人在上一个保险期间届满前提出重新投保申请。 第三条 保险期间和续保 本合同的保险期间为一年。本合同所指续保，为不保证续保。

AI 超时后的结果状态设计

Request state & message design

请求超时后，后端无法确认 AI 是否已经执行。直接重试可能重复调用。
我将无法确认的结果定义为 UNKNOWN，保留用户问题，不生成未经确认的回答。

请求状态与用户反馈

请求状态与消息写入分别管理



图 3 用户消息在请求开始时写入；AI 回答只在明确成功后写入。

为什么不自动重试

原请求可能仍在执行。自动重发会带来重复模型或工具调用，因此当前版本不自动重试。
错误提示也不作为 AI 回答写入会话。

当前方案的限制

UNKNOWN 不代表请求已经取消。当前版本尚未对账迟到结果，后续需评估状态查询或回调，再设计安全的恢复方式。

让产品规则有明确的负责人

Interaction, business control & AI execution

一次保险咨询跨越界面、业务后端与 AI 服务。
明确谁负责交互、谁确认业务状态、谁执行 AI 能力，保持用户体验与业务事实一致。

Vue：负责交互与展示	Spring Boot：负责业务事实	FastAPI / Agent：执行能力
展示输入、loading、回答与来源； 只访问业务后端，不自行判定 请求结果，也不自动重试 AI 请求。	负责鉴权、资源归属与请求保护； 判定请求状态，持久化用户、 会话与消息等业务事实。	FastAPI 负责 AI 服务入口； Agent 调用模型、工具与检索， 不接管用户与会话业务数据库。

一次请求如何跨系统完成

去程提交请求，回程确认结果；业务状态始终由 Spring Boot 判定。



数据各自记录什么

MySQL / 业务事实	Redis / 运行控制	FAISS / 检索索引
用户 · 会话 · 请求 · 消息 文档元数据由业务后端管理	近期消息缓存 · 限流 幂等加速；不替代业务事实	由知识文档派生的向量索引 由 AI / RAG 侧使用

读取超时时

读取超时 → Spring Boot 判定 UNKNOWN → 不写 Assistant 消息 → Vue 展示不确定反馈

把产品能力落到系统中

Architecture, validation & reflection

将体验、业务控制与 AI 执行分层，让产品规则有明确的实现位置。
结合端到端场景、来源追踪与本地回归记录，检验产品设计是否落地。

实现架构

用户体验

User Experience

业务与产品控制

Business Control

AI 服务边界

AI Service

Agent 能力

Agent Capabilities

检索与知识

Retrieval & Knowledge

Vue Web Client

登录 · 会话 · Chat · Knowledge · Sources

Spring Boot

Authentication · Resource Ownership · Document
Conversation · Request State · Idempotency
Rate Limit · Exception Handling · Traceld

FastAPI

请求适配 · Agent Result · Source Mapping

LangGraph Agent + DeepSeek

Premium Calculation Tool · Knowledge Retrieval Tool
Conversation Context

PDF Knowledge Base → BGE → FAISS

知识文档 → 向量表示 → 派生检索索引

BUSINESS DATA

MySQL

用户 · 会话 · 请求
消息 · 文档元数据

Redis

近期消息缓存
限流 · 幂等加速

由 Spring Boot 管理

Python 不直接访问
Java 业务数据库。

阶段验证记录

沿用项目既有记录，非本次复测。

Chrome E2E — PASS

注册 / 登录、会话、聊天、503、timeout / UNKNOWN、
PDF 上传与路由保护等场景。

19 / 19 Actual-RAG Requests

记录中的真实 RAG 请求均返回结构化 Sources；
无检索时不复用或伪造上一轮来源。

92 Java • 102 Python • 27 Vue

既有本地自动化回归记录全部通过。
阶段测试结果不代表生产 SLA。

实现后的认识

产品流程与技术实现需要一起验证。

能力之外，还要定义规则

模型能回答只是起点；用户流程、状态语义、
来源可信度与异常反馈共同构成产品体验。

不确定性需要产品语义

将 UNKNOWN 与明确失败区分，
避免把无法确认的结果包装成确定答案。

技术证据需要转为用户价值

检索结果经过清晰的来源呈现，
才能帮助用户核对回答依据。

接下来验证什么

真实用户理解 Sources 与 UNKNOWN 的验证；长条款回答与来源的阅读体验优化。
评估异步任务、状态查询或回调，安全对账迟到结果；当前版本尚未实现该能力。